

Σχεδίαση και Υλοποίηση Μη Σχεσιακής Βάσης Δεδομένων για Διαχείριση Τροχιών Πλοίων

Μελέτη Περίπτωσης: Ανάλυση Δεδομένων Λιμένα Πειραιά σε Περιβάλλον MongoDB

Antonios Papakonstantinou

Digital Systems
University Of Piraeus
Athens, Greece

antonhspap@icloud.com

Dimitrios Kostiris

Digital Systems
University Of Piraeus
Athens, Greece

dimkostir@gmail.com

ΠΕΡΙΛΗΨΗ

Η ραγδαία αύξηση των τεχνολογιών ροής δεδομένων και η εποχή των Big Data έχουν οδηγήσει στη συλλογή τεράστιων όγκων ετερογενών πληροφοριών, μετασχηματίζοντας ριζικά το τοπίο του Διαδικτύου των Πραγμάτων (IoT) και των συστημάτων μεταφορών. Στον ναυτιλιακό τομέα, τα δεδομένα που παράγονται από το Σύστημα Αυτόματης Αναγνώρισης (AIS) αποτελούν μία από τις σημαντικότερες πηγές χωροχρονικής πληροφορίας, καθώς καταγράφουν με υψηλή συχνότητα τη θέση και την κίνηση πλοίων σε πραγματικό χρόνο.

Η παρούσα εργασία εστιάζει στη διαχείριση και ανάλυση δεδομένων AIS, εμπλουτισμένων με μετεωρολογικές πληροφορίες, με γεωγραφική εστίαση στην ευρύτερη θαλάσσια περιοχή του λιμανιού του Πειραιά. Αν και το αρχικό σύνολο δεδομένων καλύπτει την περίοδο 2017–2019 και περιλαμβάνει εκατοντάδες εκατομμύρια εγγραφές, στο πλαίσιο της παρούσας μελέτης χρησιμοποιείται υποσύνολο δεδομένων που αντιστοιχεί στον Δεκέμβριο του 2018, ώστε να διατηρηθεί ισορροπία μεταξύ όγκου δεδομένων και αποδοτικής ανάλυσης.

Κεντρικός στόχος της εργασίας είναι η μετάβαση από την απλή αποθήκευση μεμονωμένων καταγραφών AIS στη μοντελοποίηση σύνθετων αντικειμένων, μέσω της έννοιας της τροχιάς πλοίου. Κάθε τροχιά αναπαριστά τη χρονικά διατεταγμένη κίνηση ενός πλοίου και εμπλουτίζεται με δυναμικά χαρακτηριστικά κίνησης, καθώς και περιβαλλοντικές παραμέτρους, όπως η θερμοκρασία και η ένταση του ανέμου. Για την αποθήκευση και επεξεργασία των δεδομένων επιλέγεται η MongoDB, αξιοποιώντας τις δυνατότητές της για αποθήκευση σύνθετων εγγράφων, χωρικά ευρετήρια και aggregation ερωτήματα, ενώ η υλοποίηση πραγματοποιείται σε περιβάλλον Docker για λόγους αναπαραγωγιμότητας και ευκολίας εγκατάστασης.

Τέλος, υλοποιούνται και αξιολογούνται σύνθετα χωροχρονικά και σημασιολογικά ερωτήματα, με έμφαση στην επίδραση των ευρετηρίων και του όγκου δεδομένων στην απόδοση. Τα αποτελέσματα δείχνουν ότι ο προτεινόμενος σχεδιασμός υποστηρίζει αποδοτικά την ανάλυση τροχιών πλοίων

και κλιμακώνεται ικανοποιητικά σε μεγάλα σύνολα χωροχρονικών δεδομένων.

ΛΕΞΕΙΣ ΚΛΕΙΔΙΑ: Τροχίες πλοίων, Χωροχρονικά δεδομένα, MongoDB, NoSQL βάσεις δεδομένων, Χωρικά ευρετήρια

Σχετικές εργασίες και ανασκόπηση βιβλιογραφίας

Η παρούσα εργασία εντάσσεται στο ευρύτερο πεδίο της διαχείρισης και ανάλυσης δεδομένων μεγάλης κλίμακας (Big Data), με έμφαση σε χωροχρονικά δεδομένα πλοίων και συγκεκριμένα στη ναυτιλία. Το θεωρητικό υπόβαθρο της εργασίας βασίζεται στις έννοιες και τις τεχνικές που παρουσιάστηκαν στο μάθημα «*Διαχείριση Δεδομένων για Σχεσιακές και Μη-Σχεσιακές Βάσεις Δεδομένων*», μέσα από τις διαλέξεις, τις σημειώσεις και το συνοδευτικό εκπαιδευτικό υλικό.

Ιδιαίτερη έμφαση δίνεται στη μετάβαση από τα παραδοσιακά σχεσιακά μοντέλα σε NoSQL βάσεις δεδομένων, στη διαχείριση μεγάλων όγκων δεδομένων, καθώς και στη χρήση χωρικών και χρονικών ευρετηρίων για αποδοτική επεξεργασία σύνθετων ερωτημάτων.

Στο πλαίσιο της διεθνούς βιβλιογραφίας, ιδιαίτερη συνάφεια με την παρούσα εργασία παρουσιάζει η δημοσίευση “*The Piraeus AIS dataset for large-scale maritime data analytics*”¹ η οποία αποτελεί και τη βασική πηγή των δεδομένων που αξιοποιήθηκαν στην παρούσα μελέτη.

Στην εργασία αυτή παρουσιάζεται ένα εκτεταμένο σύνολο δεδομένων AIS, το οποίο καλύπτει την ευρύτερη περιοχή του λιμανιού του Πειραιά για χρονικό διάστημα άνω των 2,5 ετών (Μάιος 2017 – Δεκέμβριος 2019).

¹ [The Piraeus AIS dataset for large-scale maritime data analytics - ScienceDirect](#)

Σχεδίαση και Υλοποίηση Μη Σχεσιακής Βάσης Δεδομένων για Διαχείριση Τροχιών Πλοίων

Το dataset περιλαμβάνει περισσότερες από 244 εκατομμύρια δυναμικές καταγραφές πλοίων, εμπλουτισμένες με στατικά χαρακτηριστικά πλοίων, γεωγραφικά δεδομένα και μετεωρολογικές πληροφορίες, καθιστώντας το ένα από τα μεγαλύτερα και πυκνότερα ανοιχτά σύνολα δεδομένων AIS που έχουν δημοσιευθεί μέχρι σήμερα.

Η συγκεκριμένη εργασία περιγράφει αναλυτικά τη διαδικασία συλλογής, καθαρισμού και εμπλουτισμού των δεδομένων, καθώς και τη δημιουργία σύντομης τροχιών (trajectory synopses), μέσω της αναγνώρισης κρίσιμων γεγονότων κίνησης όπως αλλαγές ταχύτητας, στάσεις και χρονικά κενά. Ωστόσο, η εστίαση της δημοσίευσης βρίσκεται κυρίως στη διάθεση και τεκμηρίωση του dataset ως ερευνητικού πόρου, καθώς και στην περιγραφή ενός αφηρημένου μοντέλου βάσης δεδομένων, χωρίς να εξετάζεται σε βάθος η πρακτική υλοποίηση πολύπλοκων ερωτημάτων πάνω σε NoSQL συστήματα.

Η παρούσα εργασία έρχεται να συμπληρώσει τη συγκεκριμένη προσέγγιση, εστιάζοντας στη μοντελοποίηση των δεδομένων σε MongoDB και στη μετατροπή των απλών καταγραφών AIS σε σύνθετα έγγραφα τροχιών. Σε αντίθεση με την αρχική παρουσίαση του dataset, εδώ δίνεται έμφαση στον σχεδιασμό του σχήματος της βάσης, στη χρήση εμφωλευμένων δομών (documents με arrays σημείων), καθώς και στη δημιουργία κατάλληλων ευρετηρίων (χρονικών, χωρικών και σύνθετων) που επιτρέπουν την αποδοτική εκτέλεση σύνθετων χωροχρονικών και θεματικών ερωτημάτων. Επιπλέον, η εργασία αξιοποιεί μόνο ένα υποσύνολο των διαθέσιμων δεδομένων (Δεκέμβριος 2018), γεγονός που επιτρέπει τον ελεγχόμενο πειραματισμό και την αξιολόγηση της απόδοσης σε ρεαλιστικές συνθήκες, χωρίς την ανάγκη πλήρους φόρτωσης του αρχικού όγκου δεδομένων.

Συνολικά, η παρούσα εργασία βασίζεται στο θεωρητικό και πρακτικό υπόβαθρο που παρουσιάζεται τόσο στο εκπαιδευτικό υλικό του μαθήματος όσο και στη σχετική βιβλιογραφία, επεκτείνοντας την υπάρχουσα γνώση με μια πλήρη, πρακτική και τεκμηριωμένη υλοποίηση διαχείρισης και ανάλυσης ναυτιλιακών χωροχρονικών δεδομένων σε περιβάλλον NoSQL.

Σύνολο δεδομένων που χρησιμοποιήθηκε και ορισμός ερωτημάτων

Σύνολο δεδομένων που χρησιμοποιήθηκε

Στην παρούσα εργασία δεν χρησιμοποιείται απευθείας το αρχικό σύνολο δεδομένων AIS, αλλά ένα νέο, τελικό σύνολο δεδομένων που προέκυψε μετά από διαδικασία επιλογής, προεπεξεργασίας και εμπλουτισμού. Η επιλογή αυτή είναι απαραίτητη, καθώς το αρχικό dataset περιλαμβάνει εκατοντάδες εκατομμύρια εγγραφές και πολλαπλά ετερογενή αρχεία, τα οποία

δεν είναι κατάλληλα για άμεση αποθήκευση και ανάλυση χωρίς προηγούμενη επεξεργασία.

Το τελικό σύνολο δεδομένων που χρησιμοποιήθηκε περιλαμβάνει μόνο δεδομένα του Δεκεμβρίου 2018, περιορίζοντας σκόπιμα το χρονικό εύρος ώστε να διατηρηθεί η αναλυτική αξία των δεδομένων, χωρίς να καθίσταται μη διαχειρίσιμος ο όγκος τους. Το dataset αυτό συνδυάζει τρεις κύριες πηγές πληροφορίας:

1. Δυναμικά δεδομένα AIS
2. Στατικά χαρακτηριστικά πλοίων
3. Μετεωρολογικές πληροφορίες

Τα δυναμικά δεδομένα AIS περιλαμβάνουν χρονικές καταγραφές θέσης και κίνησης πλοίων, όπως γεωγραφικές συντεταγμένες, ταχύτητα, πορεία και κατεύθυνση.

Τα στατικά δεδομένα AIS παρέχουν πληροφορίες που δεν μεταβάλλονται στον χρόνο, όπως το αναγνωριστικό του πλοίου (vessel_id), η χώρα προέλευσης και ο τύπος του πλοίου.

Οι μετεωρολογικές πληροφορίες προέρχονται από ένα σύνολο μετρήσεων και αντιστοιχίζονται στις καταγραφές AIS βάσει χωρικής κατάταξης και χρονικής ευθυγράμμισης ανά ώρα.

Εξέταση σχήματος και παραγωγή τελικού dataset

Πριν την παραγωγή του τελικού dataset, πραγματοποιήθηκε διερεύνηση της δομής των αρχείων και του σχήματος των δεδομένων. Για τον σκοπό αυτό εκτελέστηκε script σε περιβάλλον Google Colab, το οποίο φόρτωσε δειγματικά τα αρχεία CSV και shapefiles και εκτύπωσε τις διαθέσιμες στήλες κάθε συνόλου δεδομένων. Η διαδικασία αυτή επέτρεψε την κατανόηση του περιεχομένου των αρχείων και την επιλογή μόνο των πεδίων που είναι απαραίτητα για την υλοποίηση των ερωτημάτων της εργασίας.

Στη συνέχεια, πραγματοποιήθηκε συγχώνευση των δυναμικών και στατικών δεδομένων AIS με βάση το κοινό πεδίο vessel_id. Ακολούθως, τα δεδομένα εμπλουτίστηκαν με μετεωρολογική πληροφορία, χρησιμοποιώντας χωρική αντιστοίχιση τύπου nearest-neighbor και χρονική στρογγυλοποίηση των χρονικών στιγμών ανά ώρα. Το αποτέλεσμα της διαδικασίας αυτής είναι ένα ενιαίο, εμπλουτισμένο dataset, στο οποίο κάθε καταγραφή AIS συνοδεύεται από πληροφορίες κίνησης, στατικά χαρακτηριστικά πλοίου και περιβαλλοντικές συνθήκες.

Το τελικό σύνολο δεδομένων εξήχθη σε αρχείο CSV και αποτελεί το μοναδικό dataset που χρησιμοποιείται στη συνέχεια της εργασίας για την αποθήκευση στη βάση δεδομένων και την εκτέλεση των ερωτημάτων.

Το όνομα του αρχείου: **ais_dec2018_enriched**

Ορισμός των ενεργειών που υλοποιήθηκαν

Με βάση το παραπάνω σύνολο δεδομένων, υλοποιήθηκαν δύο βασικές κατηγορίες ερωτημάτων, σύμφωνα με τις απαιτήσεις της εργασίας.

Το πρώτο σκέλος της υλοποίησης μας αφορά την ανάκτηση τροχιών πλοίων που ικανοποιούν ταυτόχρονα χωρικά, χρονικά και θεματικά κριτήρια. Συγκεκριμένα, το ερώτημα συνδυάζει φίλτρα γεωγραφικής περιοχής, χρονικού διαστήματος, περιβαλλοντικών συνθηκών (όπως ένταση ανέμου) και γεγονότων που έχουν ανιχνευθεί κατά μήκος των τροχιών, αξιοποιώντας πληροφορία από σύνοψη τροχιών (trajectory annotations). Το ερώτημα αυτό καταδεικνύει τη δυνατότητα συνδυαστικής ανάλυσης χωρικών, χρονικών και σημασιολογικών χαρακτηριστικών.

Το δεύτερο σκέλος αφορά την καταμέτρηση και στατιστική ανάλυση τροχιών που διέρχονται από συγκεκριμένο χωροχρονικό πλαίσιο. Για μία δοσμένη γεωγραφική τοποθεσία και ένα χρονικό διάστημα, υπολογίζεται ο αριθμός των τροχιών που το διασχίζουν, καθώς και βασικά στατιστικά μεγέθη που αφορούν την πυκνότητα των καταγραφών εντός της περιοχής. Το ερώτημα αυτό επιτρέπει τη μελέτη της έντασης της ναυτιλιακής δραστηριότητας και αποτελεί χαρακτηριστικό παράδειγμα χωροχρονικού aggregation².

Μοντελοποίηση και σχήμα βάσης δεδομένων

Επιλογή συστήματος βάσης δεδομένων

Για την αποθήκευση και ανάλυση των εμπλουτισμένων δεδομένων AIS επιλέχθηκε η MongoDB, ένα σύστημα διαχείρισης μη-σχεσιακών βάσεων δεδομένων (NoSQL), το οποίο υποστηρίζει εγγενώς σύνθετες και ιεραρχικές δομές δεδομένων. Η επιλογή αυτή είναι ιδιαίτερα κατάλληλη για δεδομένα χωροχρονικής φύσης, καθώς η MongoDB παρέχει ενσωματωμένη υποστήριξη για GeoJSON³ αντικείμενα και χωρικά ευρετήρια, ενώ επιτρέπει την αποδοτική αποθήκευση εγγράφων που περιλαμβάνουν μεταβλητό αριθμό εμφωλευμένων στοιχείων.

² Ως aggregation ορίζεται η διαδικασία συνδυασμού επιμέρους χωρικών ή και χρονικών παρατηρήσεων σε συνοπτικές τιμές, με σκοπό τη μελέτη γενικών προτύπων και της έντασης της δραστηριότητας αντί της ανάλυσης μεμονωμένων γεγονότων.

³ GeoJSON: Ανοικτό πρότυπο δεδομένων βασισμένο στο JSON, που χρησιμοποιείται για την αναπαράσταση γεωγραφικών αντικειμένων (π.χ. σημεία, γραμμές, πολύγωνα) και των ιδιοτήτων τους.

Σε αντίθεση με το σχεσιακό μοντέλο, όπου κάθε καταγραφή AIS θα έπρεπε να αποθηκευτεί ως ανεξάρτητη γραμμή και να συνδεθεί με πολλαπλούς πίνακες, η MongoDB επιτρέπει τη φυσική ομαδοποίηση των δεδομένων σε ανώτερες οντότητες, μειώνοντας την ανάγκη για πολύπλοκα joins και βελτιώνοντας την απόδοση των χωροχρονικών ερωτημάτων.

Έννοια της τροχιάς ως βασική οντότητα

Βασική μονάδα αποθήκευσης στη βάση δεδομένων είναι η τροχιά (trajectory) ενός πλοίου. Μια τροχιά ορίζεται ως μια χρονικά διατεταγμένη ακολουθία γεωγραφικών σημείων που περιγράφουν την κίνηση ενός συγκεκριμένου πλοίου μέσα σε ένα συγκεκριμένο χρονικό διάστημα. Κάθε σημείο της τροχιάς αντιστοιχεί σε μία καταγραφή AIS και περιλαμβάνει τόσο πληροφορίες κίνησης όσο και τις επικρατούσες περιβαλλοντικές συνθήκες.

Στο πλαίσιο της παρούσας εργασίας, υιοθετείται ο απλός κανόνας ότι μία τροχιά περιλαμβάνει όλες τις καταγραφές ενός vessel_id εντός μίας ημερολογιακής ημέρας (UTC). Η επιλογή αυτή επιτρέπει τη δημιουργία εγγράφων με ελεγχόμενο μέγεθος, αποφεύγοντας τόσο την υπερβολική κατάτμηση των δεδομένων όσο και τη δημιουργία υπερβολικά μεγάλων documents που θα επηρέαζαν αρνητικά την απόδοση.

Η αναπαράσταση της τροχιάς ως ενιαίο document αντικατοπτρίζει με φυσικό τρόπο τη συνεχή κίνηση του πλοίου στον χώρο και στον χρόνο και διευκολύνει την εκτέλεση ερωτημάτων που αφορούν ολόκληρες διαδρομές και όχι μεμονωμένα σημεία.

Δομή εγγράφου τροχιάς

Κάθε τροχιά αποθηκεύεται στη MongoDB ως ένα document, το οποίο περιλαμβάνει δύο διακριτά επίπεδα πληροφορίας:

- (α) πεδία που αφορούν ολόκληρη την τροχιά και
- (β) πεδία που αφορούν τα επιμέρους σημεία της τροχιάς.

Στο επίπεδο της τροχιάς αποθηκεύονται μεταδεδομένα που είναι κοινά για όλα τα σημεία. Το πεδίο vessel_id αποτελεί το βασικό αναγνωριστικό του πλοίου και χρησιμοποιείται τόσο για την ομαδοποίηση των καταγραφών όσο και για τη σύνδεση με άλλα σύνολα δεδομένων. Τα πεδία country και shiptype περιγράφουν στατικά χαρακτηριστικά του πλοίου και προέρχονται από το static AIS dataset. Παρότι θα μπορούσαν να αποθηκευτούν σε ξεχωριστή συλλογή, ενσωματώνονται στο document της τροχιάς ως ελεγχόμενη αποκανονικοποίηση, ώστε να επιτρέπεται γρήγορο φιλτράρισμα χωρίς επιπλέον αναζητήσεις.

Τα πεδία start_time και end_time συνοψίζουν το χρονικό εύρος της τροχιάς, αντιστοιχώντας στην πρώτη και την τελευταία χρονική καταγραφή. Η ύπαρξή τους επιτρέπει αποδοτικά χρονικά

Σχεδίαση και Υλοποίηση Μη Σχεσιακής Βάσης Δεδομένων για Διαχείριση Τροχιών Πλοίων

φίλτρα σε επίπεδο document, χωρίς να απαιτείται σάρωση ολόκληρου του πίνακα σημείων.

Το κύριο σώμα της τροχιάς αποθηκεύεται στο πεδίο points, το οποίο είναι ένας πίνακας από επιμέρους σημεία. Κάθε στοιχείο του πίνακα αντιστοιχεί σε μία χρονική καταγραφή AIS και περιλαμβάνει τον χρόνο καταγραφής (t), τη γεωγραφική θέση του πλοίου (loc) και τα δυναμικά χαρακτηριστικά της κίνησης.

Η γεωγραφική θέση αποθηκεύεται σε μορφή GeoJSON Point, ακολουθώντας το πρότυπο της MongoDB για χωρικά δεδομένα. Η επιλογή αυτή επιτρέπει τη δημιουργία χωρικών ευρετηρίων και την εκτέλεση ερωτημάτων γεωγραφικής περιοχής, όπως η εύρεση τροχιών που διέρχονται από συγκεκριμένο ορθογώνιο ή ακτίνα.

Τα πεδία speed, course και heading περιγράφουν τη στιγμιαία κατάσταση κίνησης του πλοίου και αποτελούν βασικές μεταβλητές του AIS. Η αποθήκευσή τους σε επίπεδο σημείου επιτρέπει τη μελέτη αλλαγών συμπεριφοράς κατά μήκος της τροχιάς.

Δομή εγγράφου τροχιάς

Κάθε σημείο της τροχιάς εμπλουτίζεται με μετεωρολογική πληροφορία, η οποία αποθηκεύεται στο εμφολευμένο αντικείμενο weather. Το αντικείμενο αυτό περιλαμβάνει βασικές μεταβλητές όπως θερμοκρασία, ατμοσφαιρική πίεση, σχετική υγρασία, ένταση ανέμου και βροχόπτωση. Οι μεταβλητές αυτές επιλέχθηκαν ώστε να καλύπτουν διαφορετικές πτυχές των περιβαλλοντικών συνθηκών χωρίς να επιβαρύνουν υπερβολικά το μέγεθος του εγγράφου.

Η αντιστοίχιση των μετεωρολογικών δεδομένων πραγματοποιήθηκε με χωρική μέθοδο nearest-neighbor⁴ και χρονική ευθυγράμμιση ανά ώρα. Προαιρετικά, αποθηκεύεται και το πεδίο weather_dist_m, το οποίο εκφράζει την απόσταση μεταξύ της θέσης του πλοίου και του πλησιέστερου σημείου καιρού. Το πεδίο αυτό επιτρέπει την αξιολόγηση της ποιότητας του εμπλουτισμού και τη δυνατότητα φιλτραρίσματος σημείων με χαμηλή αξιοπιστία περιβαλλοντικής πληροφορίας.

Ενδεικτικό JSON σχήμα

Η παραπάνω μοντελοποίηση αποτυπώνεται σε ένα ενδεικτικό JSON document, στο οποίο κάθε έγγραφο αντιπροσωπεύει μία πλήρως εμπλουτισμένη τροχιά πλοίου. Το σχήμα αυτό εκμεταλλεύεται τη δυνατότητα της MongoDB να αποθηκεύει

σύνθετες και ιεραρχικές δομές και αποτελεί τη βάση για την υλοποίηση των χωροχρονικών ερωτημάτων της εργασίας.

```
1 {
2   "vessel_id": 123456789,
3   "country": "GR",
4   "ship_type": "Cargo",
5   "start_time": "2018-12-01T00:00:00Z",
6   "end_time": "2018-12-01T01:00:00Z",
7   "points": [
8     {
9       "t": "2018-12-01T00:10:00Z",
10      "loc": { "type": "Point", "coordinates": [34.9351, 37.9452] },
11      "speed": 12.5,
12      "course": 85.0,
13      "heading": 90.0,
14      "weather": {
15        "TDP": 12.1,
16        "PMWL": 1012.3,
17        "RH": 70,
18        "MWD": 5.2,
19        "AWCP": 0.0
20      },
21      "weather_dist_m": 3200
22    },
23    {
24      "t": "2018-12-01T01:10:00Z",
25      "loc": { "type": "Point", "coordinates": [34.9880, 37.9200] },
26      "speed": 11.8,
27      "course": 88.0,
28      "heading": 91.0,
29      "weather": {
30        "TDP": 11.7,
31        "PMWL": 1011.9,
32        "RH": 73,
33        "MWD": 5.7,
34        "AWCP": 0.0
35      },
36      "weather_dist_m": 2800
37    }
38  ]
39 }
```

Εικόνα 1. Ενδεικτική αναπαράσταση εγγράφου τροχιάς στη MongoDB.

⁴ Η μέθοδος nearest-neighbor είναι τεχνική χωρικής αντιστοίχισης κατά την οποία κάθε παρατήρηση συσχετίζεται με την πλησιέστερη χωρικά διαθέσιμη μέτρηση, θεωρώντας ότι αυτή αντιπροσωπεύει επαρκώς τις τοπικές συνθήκες.

Τεχνικές αποδοτικής επεξεργασίας

Γενική προσέγγιση ερωτημάτων

Μετά τη μοντελοποίηση και την αποθήκευση των δεδομένων στη MongoDB, το επόμενο κρίσιμο στάδιο της εργασίας αφορά την υλοποίηση σύνθετων ερωτημάτων πάνω στο σύνολο των τροχιών. Στόχος των ερωτημάτων δεν είναι απλώς η ανάκτηση μεμονωμένων εγγράφων, αλλά η υποστήριξη χωροχρονικών, περιβαλλοντικών και σημασιολογικών συνθηκών, οι οποίες αντανακλούν ρεαλιστικά σενάρια ανάλυσης ναυτιλιακής κίνησης.

Για τον λόγο αυτό, η εργασία αξιοποιεί εκτενώς το aggregation framework της MongoDB, το οποίο επιτρέπει την επεξεργασία δεδομένων μέσω ακολουθιών σταδίων (pipelines). Με τον τρόπο αυτό, είναι δυνατός ο συνδυασμός φίλτρων, ομαδοποιήσεων, υπολογισμών και συνενώσεων συλλογών, χωρίς τη μεταφορά μεγάλου όγκου δεδομένων εκτός της βάσης.

Χωροχρονικά ερωτήματα πάνω σε τροχιές

Ένα βασικό είδος ερωτημάτων που υποστηρίζεται αφορά την ανάκτηση τροχιών οι οποίες διέρχονται από συγκεκριμένες γεωγραφικές περιοχές και χρονικά διαστήματα. Τα ερωτήματα αυτά υλοποιούνται μέσω συνδυασμού χρονικών φίλτρων στα πεδία start_time και end_time και χωρικών φίλτρων πάνω στο πεδίο points.loc.

Η χρήση του τελεστή \$elemMatch επιτρέπει τον έλεγχο ύπαρξης τουλάχιστον ενός σημείου της τροχιάς που ικανοποιεί ταυτόχρονα χωρικές και περιβαλλοντικές συνθήκες. Με τον τρόπο αυτό, αποφεύγεται η ανάγκη πλήρους αποσύνθεσης του πίνακα points, διατηρώντας την αποδοτικότητα του ερωτήματος ακόμη και σε τροχιές με χιλιάδες σημεία.

Τυπικά παραδείγματα τέτοιων ερωτημάτων περιλαμβάνουν την εύρεση τροχιών που διέρχονται από συγκεκριμένο ορθογώνιο γεωγραφικής περιοχής εντός καθορισμένου χρονικού πλαισίου, καθώς και τον περιορισμό σε σημεία με έντονα καιρικά φαινόμενα, όπως αυξημένη ένταση ανέμου.

```
db.trajectories.aggregate([
  // (1) Περιορίζουμε υποψηφίες τροχιές με βάση το χρόνο
  {
    $match: {
      start_time: { $lt: ISODate("2018-12-07T00:00:00.000Z") },
      end_time: { $gte: ISODate("2018-12-04T00:00:00.000Z") }
    }
  },

  // (2) Κρατάμε τα points που είναι μέσα στο box κ έχουν WSPD > 2
  {
    $set: {
      points_in_box_windy: {
        $filter: {
          input: "$points",
          as: "p",
          cond: {
            $and: [
              // Geowithin box: lon in [23.4, 23.9], lat in [37.7, 38.1]
              { $gte: [ { $arrayElemAt: [ "$p.loc.coordinates", 0 ] }, 23.4 ] },
              { $lte: [ { $arrayElemAt: [ "$p.loc.coordinates", 0 ] }, 23.9 ] },
              { $gte: [ { $arrayElemAt: [ "$p.loc.coordinates", 1 ] }, 37.7 ] },
              { $lte: [ { $arrayElemAt: [ "$p.loc.coordinates", 1 ] }, 38.1 ] },
              { $gt: [ "$p.weather.WSPD", 2 ] }
            ]
          }
        }
      }
    }
  },

  // (3) Πετάμε τις τροχιές που τελικά δεν είχαν κανένα τέτοιο σημείο
  {
    $match: {
      $expr: { $gt: [ { $size: "$points_in_box_windy" }, 0 ] }
    }
  },

  // (4) Lookup: φέρνουμε annotations
  {
    $lookup: {
      from: "trajectory_annotations_clean",
      localField: "trajectory_id",
      foreignField: "trajectory_id",
      as: "ann"
    }
  },

  // (5) Υπολογίζουμε μετρικές για το πόσο windy ήταν μέσα στο box
  {
    $project: {
      _id: 0,
      trajectory_id: 1,
      vessel_id: 1,
      country: 1,
      shiptype: 1,
      start_time: 1,
      end_time: 1,

      n_points_in_box_windy: { $size: "$points_in_box_windy" },

      avg_wspd_in_box: { $avg: "$points_in_box_windy.weather.WSPD" },
      max_wspd_in_box: { $max: "$points_in_box_windy.weather.WSPD" },
      min_wspd_in_box: { $min: "$points_in_box_windy.weather.WSPD" },

      // Δίνω 3 σημείων για να φαίνεται το αποτέλεσμα (χρόνος, coords, ανεμος)
      sample_points: {
        $slice: [
          {
            $map: {
              input: "$points_in_box_windy",
              as: "p",
              in: {
                t: "$p.t",
                coords: "$p.loc.coordinates",
                wspd: "$p.weather.WSPD",
                tmp: "$p.weather.TMP"
              }
            }
          },
          3
        ]
      }
    }
  },

  // Μετράω πόσα GAP_END υπάρχουν σε αυτά τα annotations (αν υπάρχουν)
  {
    $set: {
      n_gap_end_events: {
        $filter: {
          input: "$ann",
          as: "a",
          cond: { $in: [ "GAP_END", "$a.annotations" ] }
        }
      }
    }
  },

  // (6) Ταξινόμηση μέσα στο box (με max wind)
  { $sort: { max_wspd_in_box: -1, n_points_in_box_windy: -1 } },

  // (7) Δίνουμε 5 αποτελέσματα
  { $limit: 5 }
])
```

Εικόνα 2. Σύνθετο aggregation pipeline στη MongoDB για ανάκτηση τροχιών που επικαλύπτονται το χρονικό διάστημα 04–07/12/2018 και περιέχουν σημεία εντός ορθογωνίου περιοχής ενδιαφέροντος (Πειραιάς) με συνθήκη ανέμου WSPD>2. Το pipeline φιλτράρει σημεία (points), υπολογίζει μετρικές έντασης ανέμου εντός περιοχής (min/avg/max), και ενώνει σημασιολογικές επισημάνσεις μέσω \$lookup..

Σχεδίαση και Υλοποίηση Μη Σχεσιακής Βάσης Δεδομένων για Διαχείριση Τροχιών Πλοίων

```
[
  {
    vessel_id: '7363e97688ab4c41ab7d418a101b9b748da815e9c23546a8dddb69a887537e3',
    country: 'Panama',
    shiptype: 70,
    start_time: ISODate('2018-12-06T00:12:18.000Z'),
    end_time: ISODate('2018-12-06T06:05:26.000Z'),
    trajectory_id: 'vessel_7363e97688ab4c41ab7d418a101b9b748da815e9c23546a8dddb69a887537e3_2018-12-06',
    n_points_in_box_windy: 74,
    avg_wspd_in_box: 8.02262952685635,
    max_wspd_in_box: 10.48340957839451,
    min_wspd_in_box: 6.896026993807713,
    sample_points: [
      {
        t: ISODate('2018-12-06T00:12:18.000Z'),
        coords: [ 23.5509566666667, 37.067433333333295 ],
        wspd: 7.441037555475921,
        tmp: 281.83228
      },
      {
        t: ISODate('2018-12-06T00:12:18.000Z'),
        coords: [ 23.5509566666667, 37.067433333333295 ],
        wspd: 7.441037555475921,
        tmp: 281.83228
      },
      {
        t: ISODate('2018-12-06T00:15:18.000Z'),
        coords: [ 23.550268333333307, 37.06726 ],
        wspd: 7.441037555475921,
        tmp: 281.83228
      }
    ],
    n_gap_end_events: 0
  },
]
```

Εικόνα 3. Παραθέτουμε το πρώτο αποτέλεσμα από το προηγούμενο aggregation

Στατιστική ανάλυση τροχιών

Πέρα από την απλή ανάκτηση τροχιών, υλοποιούνται και ερωτήματα στατιστικού χαρακτήρα, τα οποία αποσκοπούν στην ποσοτική περιγραφή της κίνησης. Ενδεικτικά, υπολογίζεται ο αριθμός τροχιών που διέρχονται από συγκεκριμένη περιοχή, καθώς και στατιστικά μεγέθη όπως ο μέσος, ο ελάχιστος και ο μέγιστος αριθμός σημείων ανά τροχιά.

Τα ερωτήματα αυτά υλοποιούνται με χρήση των σταδίων \$project, \$group και \$sort του aggregation framework. Μέσω της συνάρτησης \$size υπολογίζεται το πλήθος των σημείων κάθε τροχιάς, επιτρέποντας τη μελέτη της κατανομής του όγκου δεδομένων και την αξιολόγηση της καταλληλότητας του κανόνα ορισμού της τροχιάς.

Στην επόμενη εικόνα υλοποιείται στατιστική ανάλυση των τροχιών που διέρχονται από συγκεκριμένο χωροχρονικό πλαίσιο.

Για κάθε τροχιά υπολογίζεται το πλήθος των σημείων εντός της περιοχής ενδιαφέροντος, ενώ στη συνέχεια εξαγονται συγκεντρωτικά στατιστικά μεγέθη, όπως ο συνολικός αριθμός τροχιών, καθώς και ο ελάχιστος, μέσος και μέγιστος αριθμός σημείων ανά τροχιά. Το ερώτημα αυτό παρέχει συνοπτική εικόνα της έντασης της ναυτιλιακής δραστηριότητας στην περιοχή μελέτης.

```
db.trajectories.aggregate([
  // (1) Χρονικά φίλτρα
  {
    $match: {
      start_time: { $lt: ISODate("2018-12-07T00:00:00.000Z") },
      end_time: { $gte: ISODate("2018-12-04T00:00:00.000Z") }
    }
  },
  // (2) Κρατάμε τροχιές που περνούν από το γεωγραφικό box
  {
    $match: {
      points: {
        $elemMatch: {
          loc: {
            $geoWithin: {
              $box: [
                [23.4, 37.7],
                [23.9, 38.1]
              ]
            }
          }
        }
      }
    }
  },
  // (3) Υπολογίζουμε πόσα σημεία κάθε τροχιάς είναι μέσα στο box
  {
    $project: {
      trajectory_id: 1,
      n_points_in_box: {
        $size: {
          $filter: {
            input: "$points",
            as: "p",
            cond: {
              $and: [
                { $gte: [ { $arrayElemAt: ["$$p.loc.coordinates", 0] }, 23.4 ] },
                { $lte: [ { $arrayElemAt: ["$$p.loc.coordinates", 0] }, 23.9 ] },
                { $gte: [ { $arrayElemAt: ["$$p.loc.coordinates", 1] }, 37.7 ] },
                { $lte: [ { $arrayElemAt: ["$$p.loc.coordinates", 1] }, 38.1 ] }
              ]
            }
          }
        }
      }
    }
  },
  // (4) Στατιστικά σε επίπεδο συνόλου
  {
    $group: {
      _id: null,
      trajectories_count: { $sum: 1 },
      avg_points_in_box: { $avg: "$n_points_in_box" },
      min_points_in_box: { $min: "$n_points_in_box" },
      max_points_in_box: { $max: "$n_points_in_box" }
    }
  },
  { $project: { _id: 0 } }
])
```

Εικόνα 4. Aggregation ερώτημα για στατιστική ανάλυση τροχιών σε χωροχρονικό πλαίσιο.

```
[
  {
    trajectories_count: 616,
    avg_points_in_box: 364.6233766233766,
    min_points_in_box: 1,
    max_points_in_box: 10010
  }
]
```

Εικόνα 5. Συγκεντρωτικά στατιστικά μεγέθη τροχιών εντός της περιοχής ενδιαφέροντος.

Ενοποίηση τροχιών με σημασιολογικές επισημάνσεις

Ένα σημαντικό τμήμα της εργασίας αφορά την ενσωμάτωση σημασιολογικών επισημάνσεων (annotations) που προέρχονται από ξεχωριστό σύνολο δεδομένων. Οι επισημάνσεις αυτές περιγράφουν γεγονότα όπως αλλαγές ταχύτητας, στάσεις ή χρονικά κενά στις καταγραφές και αποθηκεύονται σε ξεχωριστή συλλογή.

Η σύνδεση των τροχιών με τις επισημάνσεις υλοποιείται μέσω του σταδίου \$lookup, χρησιμοποιώντας το κοινό πεδίο trajectory_id. Με τον τρόπο αυτό, είναι δυνατή η εκτέλεση σύνθετων ερωτημάτων που συνδυάζουν χωρικά, χρονικά και σημασιολογικά κριτήρια, όπως η εύρεση τροχιών που διέρχονται από συγκεκριμένη περιοχή και περιλαμβάνουν γεγονότα συγκεκριμένου τύπου.

Η χρήση \$lookup σε συνδυασμό με επόμενα στάδια \$match και \$project επιτρέπει τον περιορισμό του αποτελέσματος μόνο στα απολύτως απαραίτητα πεδία, μειώνοντας τον όγκο των δεδομένων που επιστρέφονται.



Εικόνα 6. Aggregation ερώτημα για ενοποίηση τροχιών με σημασιολογικές επισημάνσεις μέσω \$lookup

Το ερώτημα της εικόνας 6 εκτελεί ενοποίηση (\$lookup) μεταξύ της συλλογής τροχιών και της συλλογής σημασιολογικών επισημάνσεων και στη συνέχεια φιλτράρει για γεγονότα τύπου GAP_END.

Στη συγκεκριμένη εκτέλεση, το pipeline δεν επέστρεψε αποτελέσματα, γεγονός που ερμηνεύεται ως εξής: παρότι το γεγονός GAP_END υπάρχει στο σύνολο των επισημάνσεων, δεν εντοπίστηκε τροχιά που να ικανοποιεί ταυτόχρονα :

1. Τη χρονική επικάλυψη 04–07/12/2018 και
2. Την ύπαρξη αντίστοιχης επισημάνσης για το ίδιο trajectory_id.

Το αποτέλεσμα αυτό είναι αναμενόμενο όταν τα σημασιολογικά γεγονότα είναι σχετικά σπάνια και κατανέμονται ανομοιόμορφα στον χρόνο, ειδικά όταν εξετάζουμε μικρό χρονικό παράθυρο.

```
shipDB> db.trajectory_annotations_clean.countDocuments({ annotations: "GAP_END" })
14355
```

Εικόνα 7. Το GAP_END υπάρχει στη συλλογή επισημάνσεων, ωστόσο δεν εμφανίζεται στο συγκεκριμένο χρονικό παράθυρο όταν γίνεται ενοποίηση σε επίπεδο trajectory_id.

Δημιουργία και αξιοποίηση ευρετηρίων

Για την αποδοτική εκτέλεση των παραπάνω ερωτημάτων, δημιουργήθηκαν κατάλληλα ευρετήρια στη συλλογή των τροχιών.

Συγκεκριμένα, δημιουργήθηκαν ευρετήρια στο πεδίο trajectory_id για μοναδική ταυτοποίηση, σύνθετα ευρετήρια στα πεδία vessel_id και start_time για γρήγορα χρονικά φίλτρα, καθώς και χωρικό ευρετήριο τύπου 2dsphere⁵ στο πεδίο points.loc για την υποστήριξη γεωχωρικών ερωτημάτων.

Η ύπαρξη των ευρετηρίων επιτρέπει στη MongoDB να περιορίζει δραστικά τον αριθμό των εγγράφων που εξετάζονται κατά την εκτέλεση των aggregation pipelines, γεγονός που είναι κρίσιμο σε σύνολα δεδομένων μεγάλης κλίμακας. Η αποτελεσματικότητα των ευρετηρίων επαληθεύεται πειραματικά μέσω της χρήσης της εντολής explain, η οποία δείχνει ότι τα ερωτήματα αξιοποιούν τα ευρετήρια αντί για πλήρη σάρωση συλλογών.

Τα ευρετήρια επαληθεύτηκαν μέσω της εντολής getIndexes().

⁵ 2dsphere: τύπος χωρικού ευρετηρίου στη MongoDB που επιτρέπει την αποδοτική εκτέλεση γεωχωρικών ερωτημάτων σε δεδομένα τα οποία αναπαρίστανται σε σφαιρικό γεωμετρικό μοντέλο της Γης (βάσει GeoJSON), λαμβάνοντας υπόψη την καμπυλότητα της επιφάνειας.

Ερμηνεία των indexes

- **trajectory_id_1** (unique): εγγυάται μοναδικότητα ανά τροχιά και κάνει γρήγορο join με annotations.
- **vessel_id_1_start_time_1**: γρήγορη ανάκτηση τροχιών για συγκεκριμένο πλοίο και χρονική ταξινόμηση/φίλτρα.
- **idx_time_range** (start_time, end_time): επιταχύνει queries χρονικής επικάλυψης (time window overlap).
- **idx_points_loc** (2dsphere): επιταχύνει \$geoWithin, \$near, χωρικά φίλτρα πάνω σε GeoJSON.

```
shipDB> db.trajectories.getIndexes()
[
  { v: 2, key: { _id: 1 }, name: '_id' },
  {
    v: 2,
    key: { trajectory_id: 1 },
    name: 'trajectory_id_1',
    unique: true
  },
  {
    v: 2,
    key: { vessel_id: 1, start_time: 1 },
    name: 'vessel_id_1_start_time_1'
  },
  {
    v: 2, key: { start_time: 1, end_time: 1 }, name: 'idx_time_range' },
  {
    v: 2, key: { 'points.loc': '2dsphere' },
    name: 'idx_points_loc',
    '2dsphereIndexVersion': 3
  }
]
```

Εικόνα 8. Τα ευρετήρια στο Collection Trajectories.

```
db.trajectories.explain("executionStats").aggregate([
  {
    $match: {
      start_time: { $lt: ISODate("2018-12-07T00:00:00.000Z") },
      end_time: { $gte: ISODate("2018-12-04T00:00:00.000Z") }
    },
  },
  {
    $match: {
      points: {
        $elemMatch: {
          loc: {
            $geoWithin: {
              $box: [
                [23.4, 37.7],
                [23.9, 38.1]
              ]
            }
          },
          "weather.WSPD": { $gt: 2 }
        }
      }
    },
  },
  { $limit: 5 }
])
```

Εικόνα 9. Εκτέλεση του explain query στο trajectories collection

```
executionStats: {
  executionSuccess: true,
  nReturned: 5,
  executionTimeMillis: 29,
  totalKeysExamined: 570,
  totalDocsExamined: 5,
  executionStages: {
```

Εικόνα 10. Αποτελέσματα από την εκτέλεση του explain query στο trajectories collection

Τα αποτελέσματα του explain("executionStats") δείχνουν ότι το χωροχρονικό aggregation εκτελείται με ιδιαίτερα υψηλή αποδοτικότητα.

Η εκτέλεση ολοκληρώθηκε σε μόλις **29 ms**, ενώ εξετάστηκαν μόνο **5 έγγραφα**, όσα και τα έγγραφα που τελικά επιστράφηκαν.

Παράλληλα, ο αριθμός των εξεταζόμενων κλειδιών (570) υποδηλώνει την αποτελεσματική αξιοποίηση των ευρετηρίων, ιδιαίτερα του χωρικού 2dsphere index και των χρονικών indexes.

Το αποτέλεσμα αυτό επιβεβαιώνει ότι ο σχεδιασμός του σχήματος και η επιλογή των ευρετηρίων επιτρέπουν την αποδοτική εκτέλεση σύνθετων χωροχρονικών ερωτημάτων ακόμη και σε μεγάλης κλίμακας δεδομένα.

Εν κατακλείδι

Η υλοποίηση των ερωτημάτων αποδεικνύει ότι το προτεινόμενο σχήμα δεδομένων, σε συνδυασμό με τις τεχνικές του aggregation framework και τη σωστή χρήση ευρετηρίων, επιτρέπει την αποδοτική επεξεργασία σύνθετων χωροχρονικών και σημασιολογικών ερωτημάτων.

Η προσέγγιση αυτή καθιστά εφικτή την ανάλυση μεγάλης κλίμακας ναυτιλιακών δεδομένων με τρόπο εύηλεκτο και επεκτάσιμο, αξιοποιώντας πλήρως τις δυνατότητες των NoSQL συστημάτων.

Πειραματική αξιολόγηση και ανάλυση απόδοσης

Στόχος πειραματικής αξιολόγησης

Σκοπός της πειραματικής αξιολόγησης είναι η διερεύνηση της απόδοσης του προτεινόμενου σχήματος και των ερωτημάτων που υλοποιήθηκαν, καθώς και η αποτίμηση της επίδρασης των ευρετηρίων στην ταχύτητα εκτέλεσης. Η αξιολόγηση εστιάζει σε σενάρια που αντικατοπτρίζουν ρεαλιστικά ερωτήματα ανάλυσης ναυτιλιακής κίνησης, συνδυάζοντας χωρικά, χρονικά, μετεωρολογικά και σημασιολογικά κριτήρια.

Όλα τα πειράματα εκτελέστηκαν πάνω στο τελικό σύνολο δεδομένων που δημιουργήθηκε από τον εμπλουτισμό των δεδομένων AIS του Δεκεμβρίου 2018, όπως περιγράφηκε στα προηγούμενα κεφάλαια. Η βάση δεδομένων φιλοξενήθηκε σε MongoDB εκτελούμενη εντός Docker container, σε περιβάλλον τοπικού υπολογιστή.

Περιγραφή πειραματικών σεναρίων

Η αξιολόγηση βασίστηκε σε τρεις βασικές κατηγορίες ερωτημάτων.


1. Στην πρώτη κατηγορία περιλαμβάνονται χωρικά ερωτήματα, τα οποία αναζητούν τροχιές που διέρχονται από συγκεκριμένες γεωγραφικές περιοχές. Τα ερωτήματα αυτά αξιοποιούν το χωρικό ευρετήριο τύπου 2dsphere και επιτρέπουν την αποτίμηση της αποδοτικότητας της γεωχωρικής αναπαράστασης των σημείων της τροχιάς.
2. Η δεύτερη κατηγορία αφορά συνδυαστικά χωροχρονικά και περιβαλλοντικά ερωτήματα, όπου εκτός από τη γεωγραφική θέση λαμβάνονται υπόψη χρονικοί περιορισμοί και μετεωρολογικές συνθήκες, όπως αυξημένη ένταση ανέμου. Τα ερωτήματα αυτά είναι ιδιαίτερα απαιτητικά, καθώς προϋποθέτουν τον έλεγχο ύπαρξης τουλάχιστον ενός σημείου ανά τροχιά που ικανοποιεί ταυτόχρονα όλα τα κριτήρια.
3. Η τρίτη κατηγορία ερωτημάτων περιλαμβάνει συνενώσεις τροχιών με σημασιολογικές επισημάνσεις, μέσω της χρήσης του τελεστή \$lookup. Στόχος είναι η εύρεση τροχιών που πληρούν συγκεκριμένα χωρικά ή χρονικά κριτήρια και παράλληλα περιλαμβάνουν γεγονότα συγκεκριμένου τύπου, όπως αλλαγές ταχύτητας ή χρονικά κενά στις καταγραφές.

Μετρικές αξιολόγησης

Για την αξιολόγηση της απόδοσης χρησιμοποιήθηκαν κυρίως οι χρόνοι εκτέλεσης των ερωτημάτων και ο αριθμός των εγγράφων που εξετάζονται κατά την επεξεργασία. Οι χρόνοι εκτέλεσης μετρήθηκαν μέσω επαναλαμβανόμενων εκτελέσεων των ίδιων aggregation pipelines, ώστε να περιοριστεί η επίδραση τυχαίων παραγόντων.

Επιπλέον, αξιοποιήθηκε η εντολή explain της MongoDB για την ανάλυση των πλάνων εκτέλεσης. Μέσω αυτής, κατέστη δυνατή η επιβεβαίωση της χρήσης των κατάλληλων ευρετηρίων και η αποφυγή πλήρους σάρωσης των συλλογών.

Πείραμα απόδοσης: Επίδραση χωρικού ευρετηρίου (2dsphere)



Εικόνα 11. Εκτέλεση του explain query στο trajectories collection

```
executionStats: {
  executionSuccess: true,
  nReturned: 1,
  executionTimeMillis: 19,
  totalKeysExamined: 566,
  totalDocsExamined: 1,
  executionStages: {
```

Εικόνα 12. Αποτελέσματα explain("executionStats") για το χωροχρονικό ερώτημα με ενεργό χωρικό ευρετήριο (2dsphere) στο points.loc.

Στη συνέχεια, θα ρίξουμε προσωρινά το χωρικό ευρετήριο idx_points_loc για να ξανατρέξουμε το ίδιο explain χωρίς κάποιο ευρετήριο.

```
shipDB> db.trajectories.dropIndex("idx_points_loc")
{ nIndexesWas: 5, ok: 1 }
```

Εικόνα 13. Προσωρινή αφαίρεση του χωρικού ευρετηρίου idx_points_loc για αξιολόγηση της επίδρασής του στην απόδοση.

Στην συνέχεια, ξανά εκτελούμε το explain query και έχουμε:

```
executionStats: {
  executionSuccess: true,
  nReturned: 1,
  executionTimeMillis: 2,
  totalKeysExamined: 566,
  totalDocsExamined: 1,
  executionStages: {
```

Εικόνα 13. Προσωρινή αφαίρεση του χωρικού ευρετηρίου idx_points_loc για αξιολόγηση της επίδρασής του στην απόδοση.

Από τα αποτελέσματα του explain("executionStats") παρατηρείται ότι, για το συγκεκριμένο ερώτημα με περιορισμό limit = 1, ο χρόνος εκτέλεσης χωρίς το χωρικό ευρετήριο εμφανίζεται μικρότερος. Το φαινόμενο αυτό εξηγείται από το γεγονός ότι το ερώτημα επιστρέφει ελάχιστα έγγραφα και το χρονικό φίλτρο περιορίζει ήδη σημαντικά τον χώρο αναζήτησης.

Σε τέτοιες περιπτώσεις, το κόστος χρήσης του ευρετηρίου μπορεί να υπερβαίνει το κόστος άμεσης προσπέλασης των δεδομένων. Ωστόσο, η ύπαρξη του χωρικού ευρετηρίου παραμένει κρίσιμη για ερωτήματα που επιστρέφουν μεγαλύτερο αριθμό εγγράφων ή εκτελούνται σε ευρύτερες χωρικές περιοχές, όπου διαφορετικά θα απαιτούνταν πλήρης σάρωση της συλλογής.

Συμπεράσματα

Στην παρούσα εργασία μελετήθηκε η διαχείριση και ανάλυση μεγάλου όγκου χωροχρονικών δεδομένων ναυτιλιακής κινητικότητας με χρήση συστημάτων NoSQL. Αξιοποιήθηκαν δεδομένα AIS εμπλουτισμένα με μετεωρολογικές πληροφορίες, με στόχο τη μετάβαση από απλές καταγραφές θέσης σε σύνθετες αναπαραστάσεις τροχιών πλοίων, ικανές να υποστηρίξουν αποδοτικά χωρικά, χρονικά και σημασιολογικά ερωτήματα.

Κεντρικό στοιχείο της προσέγγισης αποτέλεσε η μοντελοποίηση της τροχιάς ως βασικής οντότητας αποθήκευσης στη MongoDB. Η επιλογή αυτή επέτρεψε την ομαδοποίηση των επιμέρους καταγραφών AIS σε λογικά και διαχειρίσιμα documents, τα οποία συνδυάζουν πληροφορίες χώρου, χρόνου, δυναμικής κίνησης και περιβάλλοντος. Παράλληλα, η χρήση GeoJSON για την αποθήκευση γεωγραφικών θέσεων κατέστησε δυνατή την εκτέλεση σύνθετων χωρικών ερωτημάτων με τη βοήθεια χωρικών ευρετηρίων.

Στο πλαίσιο της εργασίας υλοποιήθηκαν ερωτήματα που καλύπτουν βασικές απαιτήσεις ανάλυσης ναυτιλιακών δεδομένων, όπως η ανάκτηση τροχιών εντός συγκεκριμένων γεωγραφικών περιοχών, η εφαρμογή χρονικών φίλτρων, καθώς και ο συνδυασμός χωρικών και μετεωρολογικών συνθηκών. Επιπλέον, ενσωματώθηκαν δεδομένα σχολιασμού (annotations) που επιτρέπουν την ανίχνευση και μελέτη ειδικών γεγονότων κατά μήκος των τροχιών, όπως διακοπές σήματος ή αλλαγές συμπεριφοράς.

Η πειραματική αξιολόγηση έδειξε ότι η χρήση κατάλληλων ευρετηρίων, και ιδιαίτερα χωρικών ευρετηρίων τύπου 2dsphere, είναι κρίσιμη για την αποδοτική εκτέλεση χωροχρονικών ερωτημάτων σε μεγάλα σύνολα δεδομένων. Παράλληλα, αναδείχθηκε ότι σε περιπτώσεις ερωτημάτων με πολύ μικρό αποτέλεσμα, το κόστος χρήσης ενός ευρετηρίου μπορεί να υπερβαίνει το όφελος, γεγονός που υπογραμμίζει τη σημασία της κατανόησης του τρόπου λειτουργίας του query planner.⁶

⁶ Ο query planner (ή query optimizer) είναι το τμήμα του Συστήματος Διαχείρισης Βάσεων Δεδομένων που αποφασίζει ποιος είναι ο πιο αποδοτικός τρόπος εκτέλεσης ενός ερωτήματος SQL. Αναλύει διαφορετικά πιθανά σχέδια εκτέλεσης (π.χ. χρήση ή όχι ευρετηρίων, σειρά συνενώσεων πινάκων, τρόπος προσπέλασης των δεδομένων) και, με βάση στατιστικά στοιχεία για τα δεδομένα, εκτιμά το κόστος τους σε χρόνο και πόρους. Στόχος του είναι να επιλέξει το σχέδιο με το μικρότερο συνολικό κόστος εκτέλεσης.

Μελλοντικές Επεκτάσεις

Αν και η εργασία καλύπτει ένα πλήρες pipeline από την προεπεξεργασία των δεδομένων έως την εκτέλεση σύνθετων ερωτημάτων, υπάρχουν σημαντικά περιθώρια μελλοντικής επέκτασης.

Ενδεικτικά, θα μπορούσε να εξεταστεί η υποστήριξη πραγματικού χρόνου (streaming) δεδομένων AIS, η εφαρμογή αλγορίθμων ανίχνευσης ανωμαλιών πάνω στις τροχιές, καθώς και η αξιοποίηση κατανεμημένων αρχιτεκτονικών για περαιτέρω βελτίωση της κλιμάκωσης.

Επιπλέον, η ενσωμάτωση πιο εξελιγμένων περιβαλλοντικών μοντέλων ή δεδομένων από πολλαπλές πηγές θα μπορούσε να εμπλουτίσει περαιτέρω την ανάλυση της συμπεριφοράς των πλοίων.

Συνολικά, η εργασία καταδεικνύει ότι οι NoSQL βάσεις δεδομένων, και ειδικότερα η MongoDB, αποτελούν μια κατάλληλη και ευέλικτη λύση για τη διαχείριση μεγάλων και πολύπλοκων χωροχρονικών δεδομένων στον ναυτιλιακό τομέα, προσφέροντας τόσο εκφραστικότητα στη μοντελοποίηση όσο και αποδοτικότητα στην ανάκτηση πληροφορίας.

ΒΙΒΛΙΟΓΡΑΦΙΑ

- [1] Διαλέξεις και σημειώσεις μαθήματος *Διαχείριση Δεδομένων για Σχεσιακές και Μη-σχεσιακές Βάσεις Δεδομένων*, Μεταπτυχιακό Πρόγραμμα Σπουδών, Πανεπιστήμιο Πειραιώς, 2024–2025.
- [2] MongoDB Inc. MongoDB Documentation.: <https://www.mongodb.com/docs/>
- [3] MongoDB Inc. MongoDB Aggregation Pipeline: <https://www.mongodb.com/docs/manual/aggregation/>
- [4] MongoDB Inc. Geospatial Indexes and Queries: <https://www.mongodb.com/docs/manual/geospatial-queries/>
- [5] Docker Inc. Docker Concepts: Images and Containers: <https://docs.docker.com/get-started/>
- [6] MongoDB Inc. Explain Results and Query Plans: <https://www.mongodb.com/docs/manual/reference/explain-results/>
- [7] MongoDB Inc. Explain Results and Query Plans: <https://www.mongodb.com/docs/manual/reference/explain-results/>
- [8] MongoDB Inc. 2dsphere Indexes: <https://www.mongodb.com/docs/manual/core/2dsphere/>